

# Autovalores y Autovectores.

José Luis Ramírez B.

March 17, 2025

- 1 Introducción
- 2 Método de las Potencias
  - Método de la Potencia Inversa
- 3 Factorización QR
  - Aceleración

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:
    - Sincronismo del sistema productor

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:
    - Sincronismo del sistema productor
    - Estabilidad del sistema ante perturbaciones



# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:
    - Sincronismo del sistema productor
    - Estabilidad del sistema ante perturbaciones
    - Planificación nuevo equipo

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:
    - Sincronismo del sistema productor
    - Estabilidad del sistema ante perturbaciones
    - Planificación nuevo equipo
    - Otros muchos

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:
    - Sincronismo del sistema productor
    - Estabilidad del sistema ante perturbaciones
    - Planificación nuevo equipo
    - Otros muchos
  - Mercados financieros.

# Introducción.

- El estudio de los autovalores de sistemas surge por doquier en muchas áreas de la ciencia, ingeniería, economía ...
  - Análisis de estructuras
  - Diseño de sistemas electrónicos
  - Análisis de sistemas eléctricos:
    - Sincronismo del sistema productor
    - Estabilidad del sistema ante perturbaciones
    - Planificación nuevo equipo
    - Otros muchos
  - Mercados financieros.
- Es también muy importante para analizar el comportamiento de métodos numéricos.

# Formulación del Problema.

## Definición:

Dada una matriz  $A \in \mathbb{C}^{n \times n}$ , calcular un valor  $\lambda \in \mathbb{C}$  y un vector  $x$  no nulo tales que

$$Ax = \lambda x$$

# Formulación del Problema.

## Definición:

Dada una matriz  $A \in \mathbb{C}^{n \times n}$ , calcular un valor  $\lambda \in \mathbb{C}$  y un vector  $x$  no nulo tales que

$$Ax = \lambda x$$

- A  $\lambda$  se le denomina autovalor o valor propio y a  $x$  su correspondiente vector propio o autovector.

# Formulación del Problema.

## Definición:

Dada una matriz  $A \in \mathbb{C}^{n \times n}$ , calcular un valor  $\lambda \in \mathbb{C}$  y un vector  $x$  no nulo tales que

$$Ax = \lambda x$$

- A  $\lambda$  se le denomina autovalor o valor propio y a  $x$  su correspondiente vector propio o autovector.
- Para que exista una solución distinta de la trivial,  $x = 0$ , el valor propio  $\lambda$  deberá ser raíz del polinomio de grado  $n$ , polinomio característico:

$$\det(A - \lambda I) = 0$$

**Definición:**

Se denomina espectro de la matriz  $A$ ,  $\sigma(A)$ , al conjunto de los valores propios de  $A$ . Es decir,

$$\sigma(A) = \{\lambda \in \mathbb{C} : \det(A - \lambda I) = 0\}.$$



**Definición:**

Se denomina espectro de la matriz  $A$ ,  $\sigma(A)$ , al conjunto de los valores propios de  $A$ . Es decir,

$$\sigma(A) = \{\lambda \in \mathbb{C} : \det(A - \lambda I) = 0\}.$$

**Definición:**

Se denomina radio espectral,  $\rho(A)$ , de una matriz  $A$  de orden  $n$ , al valor máximo de los módulos de los valores propios de la matriz:

$$\rho(A) = \max_{\lambda_i \in \sigma(A)} |\lambda_i|$$

**Definición:**

Se denomina espectro de la matriz  $A$ ,  $\sigma(A)$ , al conjunto de los valores propios de  $A$ . Es decir,

$$\sigma(A) = \{\lambda \in \mathbb{C} : \det(A - \lambda I) = 0\}.$$

**Definición:**

Se denomina radio espectral,  $\rho(A)$ , de una matriz  $A$  de orden  $n$ , al valor máximo de los módulos de los valores propios de la matriz:

$$\rho(A) = \max_{\lambda_i \in \sigma(A)} |\lambda_i|$$

- El radio espectral de una matriz es el radio del menor círculo del plano complejo centrado en el origen que contiene a todos los valores propios de la matriz.

# Propiedades.

- $A$  y  $A^t$  poseen los mismos autovalores.

# Propiedades.

- $A$  y  $A^t$  poseen los mismos autovalores.
- $A = A^t$  implica que todos sus autovalores son reales.

# Propiedades.

- $A$  y  $A^t$  poseen los mismos autovalores.
- $A = A^t$  implica que todos sus autovalores son reales.
- $A$  es inversible si y sólo si  $\lambda \neq 0, \forall \lambda$  autovalor de  $A$ .

# Propiedades.

- $A$  y  $A^t$  poseen los mismos autovalores.
- $A = A^t$  implica que todos sus autovalores son reales.
- $A$  es inversible si y sólo si  $\lambda \neq 0, \forall \lambda$  autovalor de  $A$ .
- $A$  inversible y  $\lambda$  autovalor de  $A$  entonces  $1/\lambda$  es autovalor de  $A^{-1}$ .

# Propiedades.

- $A$  y  $A^t$  poseen los mismos autovalores.
- $A = A^t$  implica que todos sus autovalores son reales.
- $A$  es inversible si y sólo si  $\lambda \neq 0, \forall \lambda$  autovalor de  $A$ .
- $A$  inversible y  $\lambda$  autovalor de  $A$  entonces  $1/\lambda$  es autovalor de  $A^{-1}$ .
- $tr(A) = \sum \lambda_i, \det(A) = \prod \lambda_i$

# Localización de valores propios.

- Si no se necesita calcular exactamente los valores propios, sino saber, en cierta medida, dónde se encuentran en el plano complejo, existen varias formas de hacerlo.



# Localización de valores propios.

- Si no se necesita calcular exactamente los valores propios, sino saber, en cierta medida, dónde se encuentran en el plano complejo, existen varias formas de hacerlo.
- La más simple surge de la relación

$$|\lambda| \leq \|A\|$$

para cualquier norma matricial inducida por una norma vectorial.

# Localización de valores propios.

- Si no se necesita calcular exactamente los valores propios, sino saber, en cierta medida, dónde se encuentran en el plano complejo, existen varias formas de hacerlo.
- La más simple surge de la relación

$$|\lambda| \leq \|A\|$$

para cualquier norma matricial inducida por una norma vectorial.

- Los valores propios de una matriz se localizan en el plano complejo, dentro del círculo centrado en el origen de radio  $\|A\|$ .

# Localización de valores propios.

## Teorema: Círculos de Gershgorin

Sea  $A \in \mathbb{C}^{n \times n}$  y definiendo los círculos de Gershgorin como los conjuntos

$$R_i = \left\{ z \in \mathbb{C} / |z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \right\}$$

entonces el espectro de  $A$  es subconjunto de la unión de los círculos, esto es:

$$\sigma(A) \subseteq \bigcup_{i=1}^n R_i = S_R$$

- Escribiendo  $A = D + P$ , donde  $D$  es diagonal y están los elementos de la diagonal de  $A$ , por lo tanto  $p_{ii} = 0 \forall i$ .

- Escribiendo  $A = D + P$ , donde  $D$  es diagonal y están los elementos de la diagonal de  $A$ , por lo tanto  $p_{ii} = 0 \forall i$ .
- Considerando  $\lambda \in \sigma(A)$ ,  $\lambda \neq a_{ii}$  y definiendo la matriz  $B_\lambda = A - \lambda I = (D - \lambda I) + P$

- Escribiendo  $A = D + P$ , donde  $D$  es diagonal y están los elementos de la diagonal de  $A$ , por lo tanto  $p_{ii} = 0 \forall i$ .
- Considerando  $\lambda \in \sigma(A)$ ,  $\lambda \neq a_{ii}$  y definiendo la matriz  $B_\lambda = A - \lambda I = (D - \lambda I) + P$
- Dado que  $B$  es singular, por lo tanto existe un vector no nulo  $x$  tal que  $B_\lambda x = 0$ , por lo tanto  $((D - \lambda I) + P)x = 0$ , luego  $x = -(D - \lambda I)^{-1}Px$  aplicando  $\|\cdot\|_\infty$  a ambos de la igualdad

$$\|x\|_\infty \leq \|(D - \lambda I)^{-1}\|_\infty \|P\|_\infty \|x\|_\infty$$

$$1 \leq \|(D - \lambda I)^{-1}\|_\infty \|P\|_\infty = \sum_{\substack{j=1 \\ j \neq k}}^n \frac{|p_{kj}|}{|a_{kk} - \lambda|} = \sum_{\substack{j=1 \\ j \neq k}}^n \frac{|a_{kj}|}{|a_{kk} - \lambda|}$$

es decir  $\lambda$  satisface la condición de pertenencia al círculo  $R_k$ . Por lo tanto si se unen todos los círculos con seguridad los autovalores estarán dentro del conjunto resultante.

**Teorema:**

$A$  y  $A^t$  tienen el mismo espectro (a los círculos de  $A^t$  los denotaremos por  $C_i$  luego  $\bigcup_{i=1}^n C_i = S_C$ ).

## Teorema:

$A$  y  $A^t$  tienen el mismo espectro (a los círculos de  $A^t$  los denotaremos por  $C_i$  luego  $\bigcup_{i=1}^n C_i = S_C$ ).

## Teorema:

$$\forall \lambda \in \sigma(A) \rightarrow \lambda \in S_R \cap S_C$$



## Ejemplo:

- Dada la matriz  $A = \frac{1}{16} \begin{bmatrix} -8 & -2 & 4 \\ -1 & 6 & 2 \\ 2 & 2 & -10 \end{bmatrix}$

- Tenemos que  $r_1 = 3/8$ ,  $r_2 = 3/16$ ,  $r_3 = 1/4$ . Los discos son:

$$R_1 = \{z \in \mathbb{C} / |z + 1/2| \leq 3/8\}, \Rightarrow -7/8 \leq z \leq -1/4$$

$$R_2 = \{z \in \mathbb{C} / |z - 3/8| \leq 3/16\}, \Rightarrow 3/16 \leq z \leq 9/16$$

$$R_3 = \{z \in \mathbb{C} / |z + 5/8| \leq 1/4\}, \Rightarrow -7/8 \leq z \leq -3/8$$

# Ejemplo:

- Dada la matriz  $A = \frac{1}{16} \begin{bmatrix} -8 & -2 & 4 \\ -1 & 6 & 2 \\ 2 & 2 & -10 \end{bmatrix}$
- Note que  $\|A\| = (1/16) \max 14, 9, 14 = 7/8$  de modo que los valores propios de  $A$  cumplen con  $|\lambda| \leq 7/8$ .
- Tenemos que  $r_1 = 3/8$ ,  $r_2 = 3/16$ ,  $r_3 = 1/4$ . Los discos son:

$$R_1 = \{z \in \mathbb{C} / |z + 1/2| \leq 3/8\}, \Rightarrow -7/8 \leq z \leq -1/4$$

$$R_2 = \{z \in \mathbb{C} / |z - 3/8| \leq 3/16\}, \Rightarrow 3/16 \leq z \leq 9/16$$

$$R_3 = \{z \in \mathbb{C} / |z + 5/8| \leq 1/4\}, \Rightarrow -7/8 \leq z \leq -3/8$$

## Ejemplo:

- Dada la matriz  $A = \frac{1}{16} \begin{bmatrix} -8 & -2 & 4 \\ -1 & 6 & 2 \\ 2 & 2 & -10 \end{bmatrix}$
- Note que  $\|A\| = (1/16) \max 14, 9, 14 = 7/8$  de modo que los valores propios de  $A$  cumplen con  $|\lambda| \leq 7/8$ .
- Se Puede mejorar este estimado con el Teorema de Gershgorin.
- Tenemos que  $r_1 = 3/8$ ,  $r_2 = 3/16$ ,  $r_3 = 1/4$ . Los discos son:

$$R_1 = \{z \in \mathbb{C} / |z + 1/2| \leq 3/8\}, \Rightarrow -7/8 \leq z \leq -1/4$$

$$R_2 = \{z \in \mathbb{C} / |z - 3/8| \leq 3/16\}, \Rightarrow 3/16 \leq z \leq 9/16$$

$$R_3 = \{z \in \mathbb{C} / |z + 5/8| \leq 1/4\}, \Rightarrow -7/8 \leq z \leq -3/8$$

# Gershgorin Circles




Figure: Círculos de Gerschgorin para la matriz  $A$ .

## Ejemplo:

- La matriz  $A$  es no singular ya que el cero esta fuera de los círculos.
- Hay un autovalor en  $R_2$  y los otros dos están en  $R_1 \cup R_3$ .
- Se puede hacer el mismo análisis para la matriz  $A^t$  y obtener otra familia de círculos  $R'_1, R'_2, R'_3$ .

$$A^t = \frac{1}{16} \begin{bmatrix} -8 & -1 & 2 \\ -2 & 6 & 2 \\ 4 & 2 & -10 \end{bmatrix}$$


- Se tiene que  $r'_1 = r_1$ ,  $r'_2 = r_2$ ,  $r'_3 = r_3$ . Los discos son:

$$R'_1 = \{z \in \mathbb{C} / |z + 1/2| \leq 3/16\}, \Rightarrow -11/16 \leq z \leq -5/16$$

$$R'_2 = \{z \in \mathbb{C} / |z - 3/8| \leq 1/4\}, \Rightarrow 1/8 \leq z \leq 5/8$$

$$R'_3 = \{z \in \mathbb{C} / |z + 5/8| \leq 3/8\}, \Rightarrow -1 \leq z \leq -1/4$$

# Círculos de Gershgorin - $A$ y $A^t$



(a) Círculos de Gershgorin para  $A$

(b) Círculos de Gershgorin para  $A^t$

Figure: Círculos de Gershgorin para  $A$  y  $A^t$

## Ejemplo:

- Se sabe que los autovalores de  $A$  y  $A^t$  coinciden, por tanto la intersección de  $(R_1 \cup R_2 \cup R_3) \cap (R'_1 \cup R'_2 \cup R'_3)$  nos da un refinamiento.

## Ejemplo:

- Se sabe que los autovalores de  $A$  y  $A^t$  coinciden, por tanto la intersección de  $(R_1 \cup R_2 \cup R_3) \cap (R'_1 \cup R'_2 \cup R'_3)$  nos da un refinamiento.
- Unión de círculos de  $A$ :
  - $R_1 : [-7/8, -1/4]$
  - $R_2 : [3/16, 9/16]$
  - $R_3 : [-7/8, -3/8]$

Union:  $[-7/8, -1/4] \cup [3/16, 9/16]$



# Ejemplo:

- Se sabe que los autovalores de  $A$  y  $A^t$  coinciden, por tanto la intersección de  $(R_1 \cup R_2 \cup R_3) \cap (R'_1 \cup R'_2 \cup R'_3)$  nos da un refinamiento.

- Unión de círculos de  $A$ :

- $R_1 : [-7/8, -1/4]$
- $R_2 : [3/16, 9/16]$
- $R_3 : [-7/8, -3/8]$

Union:  $[-7/8, -1/4] \cup [3/16, 9/16]$

- Unión de círculos de  $A^t$ :

- $R'_1 : [3/16, 9/16]$
- $R'_2 : [1/8, 5/8]$
- $R'_3 : [3/16, 9/16]$

Union:  $[-1, -1/4] \cup [1/8, 5/8]$

## Ejemplo:

- Intersección de las uniones:  $[-7/8, -1/4] \cup [3/16, 9/16]$ .

## Ejemplo:

- Intersección de las uniones:  $[-7/8, -1/4] \cup [3/16, 9/16]$ .
- Esto significa que todos los autovalores de  $A$  y  $A^t$  deben estar contenidos en los intervalos  $[-7/8, -1/4]$  (negativos) y  $[3/16, 9/16]$  (positivos).

## Ejemplo:

- Intersección de las uniones:  $[-7/8, -1/4] \cup [3/16, 9/16]$ .
- Esto significa que todos los autovalores de  $A$  y  $A^t$  deben estar contenidos en los intervalos  $[-7/8, -1/4]$  (negativos) y  $[3/16, 9/16]$  (positivos).
- No hay autovalores en los intervalos  $[-1, -7/8)$  ni  $(9/16, 5/8]$ .

## Ejemplo:

- Intersección de las uniones:  $[-7/8, -1/4] \cup [3/16, 9/16]$ .
- Esto significa que todos los autovalores de  $A$  y  $A^t$  deben estar contenidos en los intervalos  $[-7/8, -1/4]$  (negativos) y  $[3/16, 9/16]$  (positivos).
- No hay autovalores en los intervalos  $[-1, -7/8)$  ni  $(9/16, 5/8]$ .
- La matriz  $A$  no es simétrica, ya que los radios de los discos de  $A$  y  $A^t$  son diferentes.

## Ejemplo:

- Intersección de las uniones:  $[-7/8, -1/4] \cup [3/16, 9/16]$ .
- Esto significa que todos los autovalores de  $A$  y  $A^t$  deben estar contenidos en los intervalos  $[-7/8, -1/4]$  (negativos) y  $[3/16, 9/16]$  (positivos).
- No hay autovalores en los intervalos  $[-1, -7/8)$  ni  $(9/16, 5/8]$ .
- La matriz  $A$  no es simétrica, ya que los radios de los discos de  $A$  y  $A^t$  son diferentes.
- Todos los autovalores son reales, debido a que los discos están contenidos en la recta real.

## Ejemplo:

- Intersección de las uniones:  $[-7/8, -1/4] \cup [3/16, 9/16]$ .
- Esto significa que todos los autovalores de  $A$  y  $A^t$  deben estar contenidos en los intervalos  $[-7/8, -1/4]$  (negativos) y  $[3/16, 9/16]$  (positivos).
- No hay autovalores en los intervalos  $[-1, -7/8)$  ni  $(9/16, 5/8]$ .
- La matriz  $A$  no es simétrica, ya que los radios de los discos de  $A$  y  $A^t$  son diferentes.
- Todos los autovalores son reales, debido a que los discos están contenidos en la recta real.
- La matriz es invertible, ya que 0 no está en ningún disco de Gerschgorin.

# Método de las Potencias

- El objetivo de este método es hallar  $\lambda_1$  autovalor de  $A$  y un autovector  $x$  asociado a  $\lambda_1$ .



# Método de las Potencias

- El objetivo de este método es hallar  $\lambda_1$  autovalor de  $A$  y un autovector  $x$  asociado a  $\lambda_1$ .
- Supongamos que  $A \in \mathbb{R}^{n \times n}$  posee  $n$  autovalores  $\lambda_1, \lambda_2, \dots, \lambda_n$  y  $n$  autovectores asociados  $v^{(1)}, v^{(2)}, \dots, v^{(n)}$ , tales que:

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$$

entonces,  $|\lambda_1| > |\lambda_j| \forall j = 2, \dots, n$  y  $\{v^{(j)}\}$  es un conjunto de vectores linealmente independientes.

# Método de las Potencias

- Si  $x$  es un vector cualquiera en  $\mathbb{R}^n$ , el hecho de que  $\{v^{(j)}\} \forall j = 1, \dots, n$  sea linealmente independiente, implica que existen constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  tal que:

$$x = \sum_{j=1}^n \alpha_j v^{(j)}$$

# Método de las Potencias

- Si  $x$  es un vector cualquiera en  $\mathbb{R}^n$ , el hecho de que  $\{v^{(j)}\} \forall j = 1, \dots, n$  sea linealmente independiente, implica que existen constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  tal que:

$$x = \sum_{j=1}^n \alpha_j v^{(j)}$$

$$Ax = \sum_{j=1}^n \alpha_j Av^{(j)} = \sum_{j=1}^n \alpha_j \lambda_j v^{(j)}$$

# Método de las Potencias

- Si  $x$  es un vector cualquiera en  $\mathbb{R}^n$ , el hecho de que  $\{v^{(j)}\} \forall j = 1, \dots, n$  sea linealmente independiente, implica que existen constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  tal que:

$$x = \sum_{j=1}^n \alpha_j v^{(j)}$$

$$Ax = \sum_{j=1}^n \alpha_j Av^{(j)} = \sum_{j=1}^n \alpha_j \lambda_j v^{(j)}$$

$$A^2x = A(Ax) = \sum_{j=1}^n \alpha_j \lambda_j Av^{(j)} = \sum_{j=1}^n \alpha_j \lambda_j^2 v^{(j)}$$

# Método de las Potencias

- Si  $x$  es un vector cualquiera en  $\mathbb{R}^n$ , el hecho de que  $\{v^{(j)}\} \forall j = 1, \dots, n$  sea linealmente independiente, implica que existen constantes  $\alpha_1, \alpha_2, \dots, \alpha_n$  tal que:

$$x = \sum_{j=1}^n \alpha_j v^{(j)}$$

$$Ax = \sum_{j=1}^n \alpha_j Av^{(j)} = \sum_{j=1}^n \alpha_j \lambda_j v^{(j)}$$

$$A^2x = A(Ax) = \sum_{j=1}^n \alpha_j \lambda_j Av^{(j)} = \sum_{j=1}^n \alpha_j \lambda_j^2 v^{(j)}$$

$$A^k x = A^{(k-1)}(Ax) = \sum_{j=1}^n \alpha_j \lambda_j^k v^{(j)}$$

# Método de las Potencias

- Dado que

$$|\lambda_1| > |\lambda_j| \forall j = 2, \dots, n \Rightarrow \left| \frac{\lambda_j}{\lambda_1} \right| < 1 \Rightarrow \left| \frac{\lambda_j}{\lambda_1} \right|^k \xrightarrow{\forall j=2, \dots, n} 0$$

$$\sum_{j=1}^n \alpha_j \lambda_j^k v^{(j)} = \lambda_1^k \sum_{j=1}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right|^k v^{(j)} \Rightarrow \lim_{k \rightarrow \infty} A^k x = \lim_{k \rightarrow \infty} \alpha_1 \lambda_1^k v^{(1)}$$

# Método de las Potencias

- Dado que

$$|\lambda_1| > |\lambda_j| \forall j = 2, \dots, n \Rightarrow \left| \frac{\lambda_j}{\lambda_1} \right| < 1 \Rightarrow \left| \frac{\lambda_j}{\lambda_1} \right|^k \xrightarrow{\forall j=2, \dots, n} 0$$

$$\sum_{j=1}^n \alpha_j \lambda_j^k v^{(j)} = \lambda_1^k \sum_{j=1}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right|^k v^{(j)} \Rightarrow \lim_{k \rightarrow \infty} A^k x = \lim_{k \rightarrow \infty} \alpha_1 \lambda_1^k v^{(1)}$$

- Esta sucesión converge a cero si  $|\lambda_1| < 1$  y diverge si  $|\lambda_1| > 1$  siempre que  $\alpha_1 \neq 0$ .

# Método de las Potencias

- Dado que

$$|\lambda_1| > |\lambda_j| \forall j = 2, \dots, n \Rightarrow \left| \frac{\lambda_j}{\lambda_1} \right| < 1 \Rightarrow \left| \frac{\lambda_j}{\lambda_1} \right|^k \xrightarrow{\forall j=2, \dots, n} 0$$

$$\sum_{j=1}^n \alpha_j \lambda_j^k v^{(j)} = \lambda_1^k \sum_{j=1}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right|^k v^{(j)} \Rightarrow \lim_{k \rightarrow \infty} A^k x = \lim_{k \rightarrow \infty} \alpha_1 \lambda_1^k v^{(1)}$$

- Esta sucesión converge a cero si  $|\lambda_1| < 1$  y diverge si  $|\lambda_1| > 1$  siempre que  $\alpha_1 \neq 0$ .
- De esta última expresión se obtiene la manera de escalar las potencias de  $A^k x$  para que el límite sea finito y distinto de cero.



# Método de las Potencias

- Para escalar las potencias se inicia eligiendo un vector  $x^{(0)}$  tal que  $x_{p_0}^{(0)} = 1 = \|x^{(0)}\|_\infty$ .

# Método de las Potencias

- Para escalar las potencias se inicia eligiendo un vector  $x^{(0)}$  tal que  $x_{p_0}^{(0)} = 1 = \|x^{(0)}\|_\infty$ .
- Sea  $y^{(1)} = Ax^{(0)} = \sum_{j=1}^n \alpha_j \lambda_j v^{(j)}$  y sea  $\mu^{(1)} = y_{p_0}^{(1)}$ , eventualmente  $\mu^{(k)} \rightarrow \lambda_1$

$$\mu^{(1)} = y_{p_0}^{(1)} = \frac{y_{p_0}^{(1)}}{x_{p_0}^{(0)}}$$

$$= \frac{\alpha_1 \lambda_1 v_{p_0}^{(1)} + \sum_{j=2}^n \alpha_j \lambda_j v_{p_0}^{(j)}}{\alpha_1 v_{p_0}^{(1)} + \sum_{j=2}^n \alpha_j v_{p_0}^{(j)}} = \lambda_1 \left( \frac{\alpha_1 v_{p_0}^{(1)} + \sum_{j=2}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right| v_{p_0}^{(j)}}{\alpha_1 v_{p_0}^{(1)} + \sum_{j=2}^n \alpha_j v_{p_0}^{(j)}} \right)$$

# Método de las Potencias

- Sea  $p_1$  el entero más pequeño tal que  $|y_{p_1}^{(1)}| = \|y^{(1)}\|_\infty$  y sea

$$x^{(1)} = \frac{y^{(1)}}{y_{p_1}^{(1)}} = \frac{Ax^{(0)}}{y_{p_1}^{(1)}} \Rightarrow \|x^{(1)}\|_\infty = 1 = |x_{p_1}^{(1)}|$$

# Método de las Potencias

- Sea  $p_1$  el entero más pequeño tal que  $|y_{p_1}^{(1)}| = \|y^{(1)}\|_\infty$  y sea

$$x^{(1)} = \frac{y^{(1)}}{y_{p_1}^{(1)}} = \frac{Ax^{(0)}}{y_{p_1}^{(1)}} \Rightarrow \|x^{(1)}\|_\infty = 1 = |x_{p_1}^{(1)}|$$

- Se define a continuación

$$y^{(2)} = Ax^{(1)} = \frac{A^2 x^{(0)}}{y_{p_1}^{(1)}}$$

# Método de las Potencias

- Sea  $p_1$  el entero más pequeño tal que  $|y_{p_1}^{(1)}| = \|y^{(1)}\|_\infty$  y sea

$$x^{(1)} = \frac{y^{(1)}}{y_{p_1}^{(1)}} = \frac{Ax^{(0)}}{y_{p_1}^{(1)}} \Rightarrow \|x^{(1)}\|_\infty = 1 = |x_{p_1}^{(1)}|$$

- Se define a continuación

$$y^{(2)} = Ax^{(1)} = \frac{A^2 x^{(0)}}{y_{p_1}^{(1)}}$$

- Sea

$$\mu^{(2)} = y_{p_1}^{(2)} = \frac{y_{p_1}^{(2)}}{x_{p_1}^{(1)}} = \frac{\lambda_1^2 \left( \frac{\alpha_1 v_{p_1}^{(1)} + \sum_{j=2}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right|^2 v_{p_1}^{(j)}}{y_{p_1}^{(1)}} \right)}{\lambda_1 \left( \frac{\alpha_1 v_{p_1}^{(1)} + \sum_{j=2}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right| v_{p_1}^{(j)}}{y_{p_1}^{(1)}} \right)}$$

# Método de las Potencias

- Así sucesivamente. Los sucesivos vectores  $x^{(k)}$ ,  $y^{(k)}$  y los escalares  $\mu^{(k)}$  siendo

$$y^{(k)} = Ax^{(k-1)}$$

$$\mu^{(k)} = y_{p_{k-1}}^{(k)} = \lambda_1 \left( \frac{\alpha_1 v_{p_{k-1}}^{(1)} + \sum_{j=2}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right|^k v_{p_{k-1}}^{(j)}}{\alpha_1 v_{p_{k-1}}^{(1)} + \sum_{j=2}^n \alpha_j \left| \frac{\lambda_j}{\lambda_1} \right|^{k-1} v_{p_{k-1}}^{(j)}} \right)$$

y

$$x^{(k)} = \frac{y^{(k)}}{y_k^{(k)}} = \frac{A^k x^{(0)}}{y_{p_1}^{(1)} y_{p_2}^{(2)} \cdots y_{p_k}^{(k)}}$$

donde  $p_k$  es el entero más pequeño para el cual

$$|y_{p_k}^{(k)}| = \|y^{(k)}\|_{\infty}.$$

# Método de las Potencias

- De esta manera, se tiene que:

$$\lim_{k \rightarrow \infty} \mu^{(k)} = \lambda_1$$

$$x^{(0)} = \alpha_1 v^{(1)} + \alpha_2 v^{(2)} + \dots + \alpha_n v^{(n)}$$

# Método de las Potencias

- De esta manera, se tiene que:

$$\lim_{k \rightarrow \infty} \mu^{(k)} = \lambda_1$$

$$x^{(0)} = \alpha_1 v^{(1)} + \alpha_2 v^{(2)} + \dots + \alpha_n v^{(n)}$$

- Suponiendo que  $\alpha_1 \neq 0$  entonces del método de la potencia se obtiene  $\mu^{(k)} \rightarrow \lambda_1$  y  $x^{(k)} \rightarrow x$  autovector asociado a  $\lambda_1$ .



# Método de las Potencias

- De esta manera, se tiene que:

$$\lim_{k \rightarrow \infty} \mu^{(k)} = \lambda_1$$

$$x^{(0)} = \alpha_1 v^{(1)} + \alpha_2 v^{(2)} + \dots + \alpha_n v^{(n)}$$

- Suponiendo que  $\alpha_1 \neq 0$  entonces del método de la potencia se obtiene  $\mu^{(k)} \rightarrow \lambda_1$  y  $x^{(k)} \rightarrow x$  autovector asociado a  $\lambda_1$ .
- La velocidad de convergencia del método depende de la magnitud del cociente  $\frac{\lambda_2}{\lambda_1}$ . Cuanto más cercano a 1 sea el cociente más lenta será la convergencia.

# Método de las Potencias

---

**Algorithm 1:** Algoritmo de Potencia.
 

---

**input** :  $A \in \mathbb{R}^{n \times n}$ ,  $x \in \mathbb{R}^n$ , Número máximo de iteraciones  $N$ ,  
tolerancia  $TOL$ .

**output:** autovalor aproximado  $\mu$  y autovector asociado  $x$  con  
 $\|x\|_\infty = 1$ .

Hallar  $p$  con  $1 \leq p \leq n$  tal que  $|x_p| = \|x\|_\infty$

$$x = \frac{x}{x_p}$$

**for**  $k \leftarrow 1$  **to**  $N$  **do**

$y \leftarrow Ax$ ;  $\mu \leftarrow y_p$

    Hallar  $p$  con  $1 \leq p \leq n$  tal que  $|y_p| = \|y\|_\infty$

**if**  $y_p = 0$  **then**

        Salida (*autovalor*, *autovector*) =  $(0, x)$ ; Seleccionar nuevo  $x$  y  
        reiniciar; EXIT

$err \leftarrow \|x - y/y_p\|_\infty$ ;  $x = \frac{y}{y_p}$

**if**  $err < TOL$  **then**

        Salida  $(\mu, x)$  EXIT

---

# Ejemplo

Sea la matriz  $A = \begin{pmatrix} 4 & -1 & 1 \\ -1 & 3 & -2 \\ 1 & -2 & 3 \end{pmatrix}$  y el vector  $x^{(0)} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$

Se obtienen los siguientes resultados:

$k$	0	1	2	3	...	14
$x^{(k)}$	$\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1 \\ -0.25 \\ 0.25 \end{pmatrix}$	$\begin{pmatrix} 1 \\ -0.5 \\ 0.5 \end{pmatrix}$	$\begin{pmatrix} 1 \\ -0.70 \\ 0.70 \end{pmatrix}$	...	$\begin{pmatrix} 1 \\ -0.9998 \\ 0.9998 \end{pmatrix}$
$\mu^{(k)}$	—	4	4.5	5.0	...	5.9993

Parece que el valor propio dominante va a ser  $\lambda = 6$  y su vector propio asociado  $(1, -1, 1)$ .

# Método de la Potencia Inversa

## Teorema:

Si  $\lambda$  es un autovalor de la matriz  $A$  entonces  $\lambda^{-1}$  es autovalor de  $A^{-1}$

# Método de la Potencia Inversa

## Teorema:

Si  $\lambda$  es un autovalor de la matriz  $A$  entonces  $\lambda^{-1}$  es autovalor de  $A^{-1}$

## Demostración:

Por ser  $\lambda$  un autovalor de  $A$  y sea  $x$  el autovector asociado, se cumple que

$$Ax = \lambda x \Rightarrow x = A^{-1}\lambda x \Rightarrow \lambda^{-1}x = A^{-1}x$$

por lo tanto  $\lambda^{-1}$  es autovalor de  $A^{-1}$ .

# Método de la Potencia Inversa

- Consideraremos que los autovalores de  $A$  ( $A$  matriz invertible) pueden ser ordenados de manera que se cumpla:

$$0 < |\lambda_n| < |\lambda_{n-1}| \leq \cdots \leq |\lambda_2| \leq |\lambda_1|$$

# Método de la Potencia Inversa

- Consideraremos que los autovalores de  $A$  ( $A$  matriz invertible) pueden ser ordenados de manera que se cumpla:

$$0 < |\lambda_n| < |\lambda_{n-1}| \leq \cdots \leq |\lambda_2| \leq |\lambda_1|$$

- Por el teorema anterior se puede verificar que también se cumplirá:

$$|\lambda_n^{-1}| > |\lambda_{n-1}^{-1}| \geq \cdots \geq |\lambda_2^{-1}| \geq |\lambda_1^{-1}| > 0$$

# Método de la Potencia Inversa

- Consideraremos que los autovalores de  $A$  ( $A$  matriz invertible) pueden ser ordenados de manera que se cumpla:

$$0 < |\lambda_n| < |\lambda_{n-1}| \leq \cdots \leq |\lambda_2| \leq |\lambda_1|$$

- Por el teorema anterior se puede verificar que también se cumplirá:

$$|\lambda_n^{-1}| > |\lambda_{n-1}^{-1}| \geq \cdots \geq |\lambda_2^{-1}| \geq |\lambda_1^{-1}| > 0$$

- Por lo que si aplicamos el método de la potencia a  $A^{-1}$ , obtendremos el valor  $\frac{1}{|\lambda_n|}$ ; y así obtener el valor de  $\lambda_n$ , el menor valor propio de  $A$ .



# Consideraciones

- Calcular la inversa de  $A$  es muy costoso, por lo tanto en su lugar se resolverá un sistema lineal de la siguiente manera:

# Consideraciones

- Calcular la inversa de  $A$  es muy costoso, por lo tanto en su lugar se resolverá un sistema lineal de la siguiente manera:
- La iteración del método de la potencia aplicado a la matriz  $A^{-1}$  tiene la forma:

$$y^{(k)} = A^{-1}x^{(k-1)}$$

# Consideraciones

- Calcular la inversa de  $A$  es muy costoso, por lo tanto en su lugar se resolverá un sistema lineal de la siguiente manera:
- La iteración del método de la potencia aplicado a la matriz  $A^{-1}$  tiene la forma:

$$y^{(k)} = A^{-1}x^{(k-1)}$$

- Lo cual es equivalente a resolver el sistema lineal

$$Ay^{(k)} = x^{(k-1)}$$

# Método de la Potencia Inversa

- Por lo tanto la iteración del método de la potencia inversa es como sigue:

# Método de la Potencia Inversa

- Por lo tanto la iteración del método de la potencia inversa es como sigue:
- Dado  $x^{(0)}$  vector inicial tal que  $\|x^{(0)}\|_2 = 1$

$$\begin{aligned}\text{Se resuelve } Az^{(k)} &= x^{(k-1)} \\ x^{(k)} &= \frac{z^{(k)}}{\|z^{(k)}\|} \\ \lambda^{(k)} &= (x^{(k)})^t Ax^{(k)}\end{aligned}$$

# Método de la Potencia Inversa

- Por lo tanto la iteración del método de la potencia inversa es como sigue:
- Dado  $x^{(0)}$  vector inicial tal que  $\|x^{(0)}\|_2 = 1$

$$\begin{aligned}\text{Se resuelve } Az^{(k)} &= x^{(k-1)} \\ x^{(k)} &= \frac{z^{(k)}}{\|z^{(k)}\|} \\ \lambda^{(k)} &= (x^{(k)})^t Ax^{(k)}\end{aligned}$$

- Así  $\lambda^{(k)}$  es el autovalor dominante de  $A^{-1}$  y por lo tanto  $\frac{1}{\lambda^{(k)}}$  es el menor autovalor en módulo de  $A$ .

# Ejemplo



# Método de la Potencia Trasladada

- Un método para acelerar la convergencia es el método de la potencia trasladada que consiste en aplicar el método de la potencia a la matriz  $(A - \alpha I)$  en lugar de a la matriz  $A$ .



# Método de la Potencia Trasladada

- Un método para acelerar la convergencia es el método de la potencia trasladada que consiste en aplicar el método de la potencia a la matriz  $(A - \alpha I)$  en lugar de a la matriz  $A$ .

## Teorema:

Si  $\lambda$  es autovalor de una matriz  $A$  asociado a un autovector  $v$  y  $\alpha$  una constante cualquiera se verifica que  $\lambda - \alpha$  es un autovalor de  $A - \alpha I$  asociado al mismo autovector  $v$ .

# Método de la Potencia Trasladada

- Un método para acelerar la convergencia es el método de la potencia trasladada que consiste en aplicar el método de la potencia a la matriz  $(A - \alpha I)$  en lugar de a la matriz  $A$ .

## Teorema:

Si  $\lambda$  es autovalor de una matriz  $A$  asociado a un autovector  $v$  y  $\alpha$  una constante cualquiera se verifica que  $\lambda - \alpha$  es un autovalor de  $A - \alpha I$  asociado al mismo autovector  $v$ .

## Demostración:

Se sabe por hipótesis que  $Av = \lambda v$ , por lo tanto

$$\begin{aligned} Av = \lambda v &\Rightarrow Av - \alpha v = \lambda v - \alpha v \\ &\Rightarrow (A - \alpha I)v = (\lambda - \alpha)v \end{aligned}$$

# Método de la Potencia Trasladada

- Mediante un desplazamiento  $\alpha$ , es posible hacer que

$$\left| \frac{\lambda_2 - \alpha}{\lambda_1 - \alpha} \right| < \left| \frac{\lambda_2}{\lambda_1} \right|$$

y que, por lo tanto, la convergencia se acelere

# Método de la Potencia Trasladada

- Mediante un desplazamiento  $\alpha$ , es posible hacer que

$$\left| \frac{\lambda_2 - \alpha}{\lambda_1 - \alpha} \right| < \left| \frac{\lambda_2}{\lambda_1} \right|$$

y que, por lo tanto, la convergencia se acelere

- Una vez obtenido el autovalor  $\mu$  de  $A - \alpha I$ , el autovalor de  $A$  se obtiene de la siguiente manera

$$\lambda = \mu + \alpha$$

# Método de la Potencia Trasladada

- Mediante un desplazamiento  $\alpha$ , es posible hacer que

$$\left| \frac{\lambda_2 - \alpha}{\lambda_1 - \alpha} \right| < \left| \frac{\lambda_2}{\lambda_1} \right|$$

y que, por lo tanto, la convergencia se acelere

- Una vez obtenido el autovalor  $\mu$  de  $A - \alpha I$ , el autovalor de  $A$  se obtiene de la siguiente manera

$$\lambda = \mu + \alpha$$

- Esta técnica puede ser aplicada bien sea con el método de las potencias o el método de potencia inversa. En este último caso se obtiene un valor aproximado de  $\mu = (\lambda_k - \alpha)^{-1}$  y se puede recuperar  $\lambda_k$  mediante la expresión  $\lambda_k = \mu^{-1} + \alpha$ .

# Ejemplo

$$A = \begin{pmatrix} 5 & 1 & -1 \\ 0 & 6 & 1 \\ 1 & 0 & -5 \end{pmatrix}$$

Autovalores:  $-4.88959806$ ,  $4.81228115$ ,  $6.07731691$

Tomando  $x^0 = (1, 1, 1)^t$ . Para diferentes valores de  $\alpha$ , se obtiene lo siguiente para una tolerancia de  $10^{-8}$  y un máximo de 200 iteraciones.

$\alpha$	Iters	Valor obtenido	Valor final	$\ Av - \lambda v\ $
-6	109	12.07731699	6.07731699	1.18171325e-07
4	14	-8.88959806	-4.88959806	2.43544003e-08
7	11	-11.88959806	-4.88959806	2.36718243e-09
5.5	8	-10.38959806	-4.88959806	1.46884304e-09

# Potencia Trasladada

- Los resultados anteriores se pueden resumir en la siguiente tabla

Método	Ecuación	Valor com- putado
Potencia	$x^{(k+1)} = Ax^{(k)}$	máximo valor propio $\lambda_1$
Potencia inversa	$Ax^{(k+1)} = x^{(k)}$	mínimo valor pro- pio $\lambda_n$
Potencia con de- splazamiento	$x^{(k+1)} = (A - \alpha I)x^{(k)}$	valor propio más alejado de $\alpha$
Potencia inversa con desplaza- miento	$(A - \alpha I)x^{(k+1)} = x^{(k)}$	valor propio más cercano a $\alpha$

Table: Resumen Métodos de Potencias.

## Descomposición $QR$

La descomposición  $QR$  de una matriz  $A$  cuadrada es tal que:

$$A = QR$$



## Descomposición $QR$

La descomposición  $QR$  de una matriz  $A$  cuadrada es tal que:

$$A = QR$$

- $Q$  es una matriz ortogonal ( $Q^t Q = I$ )

## Descomposición $QR$

La descomposición  $QR$  de una matriz  $A$  cuadrada es tal que:

$$A = QR$$

- $Q$  es una matriz ortogonal ( $Q^t Q = I$ )
- $R$  es una matriz triangular superior.

# Descomposición $QR$

La descomposición  $QR$  de una matriz  $A$  cuadrada es tal que:

$$A = QR$$

- $Q$  es una matriz ortogonal ( $Q^t Q = I$ )
- $R$  es una matriz triangular superior.
- Si  $A$  es no singular, entonces esta factorización es única.

### Definición:

Se dice que dos matrices  $A$  y  $B$  de tamaño  $n \times n$  son similares, si existe una matriz no singular  $S$  de tamaño  $n \times n$  tal que  $A = S^{-1}BS$ . Se dice entonces que  $A$  es similar a  $B$  y por lo tanto  $B$  es similar a  $A$ ; mientras que  $S$  es una transformación de similitud.  $A$  es unitariamente similar a  $B$  si  $S$  es unitaria.

### Proposición:

Supóngase que  $A$  y  $B$  son matrices similares, es decir  $A = S^{-1}BS$ , entonces las siguientes propiedades se satisfacen

### Proposición:

Supóngase que  $A$  y  $B$  son matrices similares, es decir  $A = S^{-1}BS$ , entonces las siguientes propiedades se satisfacen

- $A$  y  $B$  poseen los mismos autovalores. De hecho  $P_A(\lambda) \equiv P_B(\lambda)$ .

### Proposición:

Supóngase que  $A$  y  $B$  son matrices similares, es decir  $A = S^{-1}BS$ , entonces las siguientes propiedades se satisfacen

- $A$  y  $B$  poseen los mismos autovalores. De hecho  $P_A(\lambda) \equiv P_B(\lambda)$ .
- $Ax = \lambda x \Rightarrow B(P^{-1}x) = \lambda(P^{-1}x)$ .

### Proposición:

Supóngase que  $A$  y  $B$  son matrices similares, es decir  $A = S^{-1}BS$ , entonces las siguientes propiedades se satisfacen

- $A$  y  $B$  poseen los mismos autovalores. De hecho  $P_A(\lambda) \equiv P_B(\lambda)$ .
- $Ax = \lambda x \Rightarrow B(P^{-1}x) = \lambda(P^{-1}x)$ .
- $Bw = \lambda w \rightarrow B(Pw) = \lambda(Pw)$ .



**Teorema:**

Supongamos que  $A$  y  $B$  son matrices similares y que  $\lambda$  es autovalor de  $A$  con autovector  $x$  asociado. Entonces  $\lambda$  es tambien autovalor de  $B$ , y si  $A = S^{-1}BS$  entonces  $Sx$  es autovector asociado a  $\lambda$  para la matriz  $B$ .

## Demostración:

Dado que  $A$  es similar a  $B$ , entonces:

$$S^{-1}BS = A$$

## Demostración:

Dado que  $A$  es similar a  $B$ , entonces:

$$S^{-1}BS = A$$

Supongamos  $x \neq 0$ , entonces

$$S^{-1}BSx = Ax = \lambda x$$

## Demostración:

Dado que  $A$  es similar a  $B$ , entonces:

$$S^{-1}BS = A$$

Supongamos  $x \neq 0$ , entonces

$$S^{-1}BSx = Ax = \lambda x$$

Al multiplicar en la izquierda por la matriz  $S$ , obtenemos:

$$BSx = \lambda Sx$$

Puesto que  $x \neq 0$  y  $S$  es no singular  $Sx \neq 0$ . Por tanto,  $Sx$  es un autovector de  $B$  asociado al autovalor  $\lambda$ .

# Algoritmo $QR$

Dada una matriz cuadrada  $A$ , se puede hallar su factorización  $QR$ , donde  $Q$  es ortogonal y  $R$  triangular superior.

Algoritmo para hallar los autovalores:

# Algoritmo $QR$

Dada una matriz cuadrada  $A$ , se puede hallar su factorización  $QR$ , donde  $Q$  es ortogonal y  $R$  triangular superior.

Algoritmo para hallar los autovalores:

**Inicio:**  $A^0 = A = QR$  (nótese que  $R = Q^t A$ )

$A^1 = RQ = Q^t A Q$  ( $A$  y  $A^1$  son similares)

# Algoritmo $QR$

Dada una matriz cuadrada  $A$ , se puede hallar su factorización  $QR$ , donde  $Q$  es ortogonal y  $R$  triangular superior.

Algoritmo para hallar los autovalores:

**Inicio:**  $A^0 = A = QR$  (nótese que  $R = Q^t A$ )

$A^1 = RQ = Q^t A Q$  ( $A$  y  $A^1$  son similares)

**Factorizar:**  $A^1 = Q^1 R^1$

$A^2 = R^1 Q^1 = Q^{1t} Q^t A Q Q^1$  (similar a  $A^1$  y  $A$ )

# Algoritmo $QR$

Dada una matriz cuadrada  $A$ , se puede hallar su factorización  $QR$ , donde  $Q$  es ortogonal y  $R$  triangular superior.

Algoritmo para hallar los autovalores:

**Inicio:**  $A^0 = A = QR$  (nótese que  $R = Q^t A$ )  
 $A^1 = RQ = Q^t A Q$  ( $A$  y  $A^1$  son similares)

**Factorizar:**  $A^1 = Q^1 R^1$   
 $A^2 = R^1 Q^1 = Q^{1t} Q^t A Q Q^1$  (similar a  $A^1$  y  $A$ )

**General:** Dado  $A^m$

**Factorizar:**  $A^m = Q^m R^m$   
 $A^{m+1} = R^m Q^m$  (similar a  $A^m, \dots, A^1, A$ )



# Algoritmo $QR$

**Nota:** Si los autovalores de  $A$  satisfacen que:

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n|$$

Entonces, las iteraciones  $A^m$  convergen a una matriz triangular superior que posee sobre la diagonal los autovalores de  $A$

$$A^m \rightarrow \begin{bmatrix} \lambda_1 & u & \cdots & u \\ 0 & \lambda_2 & \cdots & u \\ \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

# Algoritmo $QR$

¿Cómo se calculan los autovectores?

# Algoritmo $QR$

¿Cómo se calculan los autovectores?

- Notese que  $A^m = Q^{(m-1)t} \dots Q^{(1)t} Q^t A Q Q^{(1)} \dots Q^{(m-1)}$

# Algoritmo $QR$

## ¿Cómo se calculan los autovectores?

- Notese que  $A^m = Q^{(m-1)t} \dots Q^{(1)t} Q^t A Q Q^{(1)} \dots Q^{(m-1)}$
- Sea  $Q^* = Q Q^{(1)} \dots Q^{(m-1)}$

# Algoritmo $QR$

## ¿Cómo se calculan los autovectores?

- Notese que  $A^m = Q^{(m-1)t} \dots Q^{(1)t} Q^t A Q Q^{(1)} \dots Q^{(m-1)}$
- Sea  $Q^* = Q Q^{(1)} \dots Q^{(m-1)}$
- Entonces  $A^m = Q^{*t} A Q^*$

# Algoritmo $QR$

## ¿Cómo se calculan los autovectores?

- Notese que  $A^m = Q^{(m-1)t} \dots Q^{(1)t} Q^t A Q Q^{(1)} \dots Q^{(m-1)}$
- Sea  $Q^* = Q Q^{(1)} \dots Q^{(m-1)}$
- Entonces  $A^m = Q^{*t} A Q^*$

Si  $A^m$  llegará a ser diagonal, los autovectores de  $A^m$  son  $e_1, e_2, \dots, e_n$ . Dado que  $A^m$  y  $A$  son matrices similares, los autovectores de  $A$  son  $(Q^{*t})^{-1} e_i = Q^*$ , es decir **los autovectores de  $A$  son las columnas de  $Q^*$** .

# Algoritmo $QR$

## ¿Cómo se calculan los autovectores?

- Notese que  $A^m = Q^{(m-1)t} \dots Q^{(1)t} Q^t A Q Q^{(1)} \dots Q^{(m-1)}$
- Sea  $Q^* = Q Q^{(1)} \dots Q^{(m-1)}$
- Entonces  $A^m = Q^{*t} A Q^*$

Si  $A^m$  llegará a ser diagonal, los autovectores de  $A^m$  son  $e_1, e_2, \dots, e_n$ . Dado que  $A^m$  y  $A$  son matrices similares, los autovectores de  $A$  son  $(Q^{*t})^{-1} e_i = Q^*$ , es decir **los autovectores de  $A$  son las columnas de  $Q^*$** .

Si  $A$  es una matriz simétrica ( $A = A^t$ ), entonces los autovectores de  $A$  son las columnas de  $Q^*$ .

# Tridiagonalización

- Para que el algoritmo  $QR$  sea eficaz, la matriz simétrica debe poseer una forma tridiagonal.



# Tridiagonalización

- Para que el algoritmo  $QR$  sea eficaz, la matriz simétrica debe poseer una forma tridiagonal.
- Por ello, este algoritmo es un proceso de dos fases.

# Tridiagonalización

- Para que el algoritmo  $QR$  sea eficaz, la matriz simétrica debe poseer una forma tridiagonal.
- Por ello, este algoritmo es un proceso de dos fases.
- A la matriz  $A$  se le aplica una fase 1 que consiste en la tridiagonalización de la matriz.

# Tridiagonalización

- Para que el algoritmo  $QR$  sea eficaz, la matriz simétrica debe poseer una forma tridiagonal.
- Por ello, este algoritmo es un proceso de dos fases.
- A la matriz  $A$  se le aplica una fase 1 que consiste en la tridiagonalización de la matriz.
- Luego se aplica una fase 2 que es diagonalizar la matriz obtenida en la fase 1.

# Tridiagonalización

$$\begin{array}{ccc} \begin{bmatrix} x & x & x & x & x \\ x & x & x & x & x \\ x & x & x & x & x \\ x & x & x & x & x \\ x & x & x & x & x \end{bmatrix} & \xrightarrow{\text{Fase 1}} & \begin{bmatrix} x & x & & & \\ x & x & x & & \\ & x & x & x & \\ & & x & x & x \\ & & & x & x \end{bmatrix} \\ A = A^t & & T \\ & & \xrightarrow{\text{Fase 2}} & \begin{bmatrix} x & & & & \\ & x & & & \\ & & x & & \\ & & & x & \\ & & & & x \end{bmatrix} \\ & & & D \end{array}$$

# Tridiagonalización

- Dado que la matriz  $T$  es también simétrica, lo cual se asegura debido a las transformaciones de similitud realizadas, entonces aplicar el método  $QR$  es más económico.

# Tridiagonalización

- Dado que la matriz  $T$  es también simétrica, lo cual se asegura debido a las transformaciones de similitud realizadas, entonces aplicar el método  $QR$  es más económico.
- Solo se almacena la diagonal principal y la subdiagonal.

# Tridiagonalización

- Dado que la matriz  $T$  es también simétrica, lo cual se asegura debido a las transformaciones de similitud realizadas, entonces aplicar el método  $QR$  es más económico.
- Solo se almacena la diagonal principal y la subdiagonal.
- Y diagonalizar la matriz, consiste entonces en anular los  $n - 1$  elementos de la subdiagonal, es decir, la factorización  $QR$  de una matriz tridiagonal consiste en  $n - 1$  transformaciones de Givens.

# Aceleración de la convergencia del Método $QR$

- Para que la diagonalización de la matriz tridiagonal obtenida se realice de una forma más acelerada, se emplean técnicas conocidas como desplazamiento de la matriz de coeficientes.



# Aceleración de la convergencia del Método $QR$

- Para que la diagonalización de la matriz tridiagonal obtenida se realice de una forma más acelerada, se emplean técnicas conocidas como desplazamiento de la matriz de coeficientes.
- La idea consiste en aplicar la factorización  $QR$  a la matriz  $T - \sigma I$ , en vez de aplicarla solo a la matriz  $T$ , siendo  $\sigma$  un valor que cambia el espectro entero de la matriz a  $\lambda_i - \sigma$ .

# Aceleración de la convergencia del Método $QR$

- Para que la diagonalización de la matriz tridiagonal obtenida se realice de una forma más acelerada, se emplean técnicas conocidas como desplazamiento de la matriz de coeficientes.
- La idea consiste en aplicar la factorización  $QR$  a la matriz  $T - \sigma I$ , en vez de aplicarla solo a la matriz  $T$ , siendo  $\sigma$  un valor que cambia el espectro entero de la matriz a  $\lambda_i - \sigma$ .
- Si  $A$  es la matriz original y  $A_i$  es la matriz actual en la iteración  $i$ , se selecciona un escalar  $\sigma$ , para hallar la factorización  $QR$  de  $A_i - \sigma I$ , y luego devolver el desplazamiento realizado para definir la matriz  $A_{i+1}$ .

# Aceleración de la convergencia del Método $QR$

- Para que la diagonalización de la matriz tridiagonal obtenida se realice de una forma más acelerada, se emplean técnicas conocidas como desplazamiento de la matriz de coeficientes.
- La idea consiste en aplicar la factorización  $QR$  a la matriz  $T - \sigma I$ , en vez de aplicarla solo a la matriz  $T$ , siendo  $\sigma$  un valor que cambia el espectro entero de la matriz a  $\lambda_i - \sigma$ .
- Si  $A$  es la matriz original y  $A_i$  es la matriz actual en la iteración  $i$ , se selecciona un escalar  $\sigma$ , para hallar la factorización  $QR$  de  $A_i - \sigma I$ , y luego devolver el desplazamiento realizado para definir la matriz  $A_{i+1}$ .
- Si el escalar  $\sigma$  es seleccionado de modo tal que es muy cercano a un autovalor de  $A$ , esta técnica acelerará la rapidez de convergencia del método.

# Aceleración de la convergencia del Método $QR$

- Se calcula la factorización  $QR$  de la matriz  $A_i - \sigma I$

$$(A_i - \sigma I) = Q_i R_i$$

# Aceleración de la convergencia del Método $QR$

- Se calcula la factorización  $QR$  de la matriz  $A_i - \sigma I$

$$(A_i - \sigma I) = Q_i R_i$$

- Luego se reversa el desplazamiento realizado, y se tiene que:

$$A_{i+1} = R_i Q_i + \sigma I$$

- Comprobando que el desplazamiento realizado preserva la similitud, multiplicando la última ecuación por  $Q$  se tiene:

$$A_{i+1} = R_i Q_i + \sigma I \Rightarrow Q_i A_{i+1} = Q_i R_i Q_i + \sigma Q_i I$$

- Comprobando que el desplazamiento realizado preserva la similitud, multiplicando la última ecuación por  $Q$  se tiene:

$$A_{i+1} = R_i Q_i + \sigma I \Rightarrow Q_i A_{i+1} = Q_i R_i Q_i + \sigma Q_i I$$

- Se tiene que  $Q_i R_i = A_i - \sigma I$ , incorporando esta ecuación queda que:

$$Q_i A_{i+1} = (A_i - \sigma I) Q_i + \sigma Q_i I \Rightarrow Q_i A_{i+1} = A_i Q_i - \sigma Q_i + \sigma Q_i$$

- Comprobando que el desplazamiento realizado preserva la similitud, multiplicando la última ecuación por  $Q$  se tiene:

$$A_{i+1} = R_i Q_i + \sigma I \Rightarrow Q_i A_{i+1} = Q_i R_i Q_i + \sigma Q_i I$$

- Se tiene que  $Q_i R_i = A_i - \sigma I$ , incorporando esta ecuación queda que:

$$Q_i A_{i+1} = (A_i - \sigma I) Q_i + \sigma Q_i I \Rightarrow Q_i A_{i+1} = A_i Q_i - \sigma Q_i + \sigma Q_i$$

- Multiplicando por  $Q^t$  por el lado derecho llegamos a que:

$$Q_i A_{i+1} Q_i^t = A_i Q_i Q_i^t - \sigma Q_i Q_i^t + \sigma Q_i Q_i^t$$



- Comprobando que el desplazamiento realizado preserva la similitud, multiplicando la última ecuación por  $Q$  se tiene:

$$A_{i+1} = R_i Q_i + \sigma I \Rightarrow Q_i A_{i+1} = Q_i R_i Q_i + \sigma Q_i I$$

- Se tiene que  $Q_i R_i = A_i - \sigma I$ , incorporando esta ecuación queda que:

$$Q_i A_{i+1} = (A_i - \sigma I) Q_i + \sigma Q_i I \Rightarrow Q_i A_{i+1} = A_i Q_i - \sigma Q_i + \sigma Q_i$$

- Multiplicando por  $Q^t$  por el lado derecho llegamos a que:

$$Q_i A_{i+1} Q_i^t = A_i Q_i Q_i^t - \sigma Q_i Q_i^t + \sigma Q_i Q_i^t$$

- Cancelando los dos términos similares de la derecha, y dado que  $Q^t Q = Q Q^t = I$  se llega a que:

$$Q_i A_{i+1} Q_i^t = A_i$$

# Aceleración de la convergencia del Método $QR$

Existen diversas estrategias de desplazamientos, entre las cuales tenemos la de desplazamiento simple y desplazamiento implícito, que pueden ser aplicados al método  $QR$ .

# Aceleración de la convergencia del Método $QR$

Existen diversas estrategias de desplazamientos, entre las cuales tenemos la de desplazamiento simple y desplazamiento implícito, que pueden ser aplicados al método  $QR$ .

- **Desplazamiento Simple:** esta técnica está basada en el hecho de que un desplazamiento causado por un autovalor provoca una deflación, por lo tanto es sugerido seleccionar el desplazamiento  $\sigma_k$  como un autovalor aproximado. Se puede seleccionar el elemento  $(k, k)$  de la matriz  $A^{(k)}$  como valor de desplazamiento.

# Aceleración de la convergencia del Método $QR$

Existen diversas estrategias de desplazamientos, entre las cuales tenemos la de desplazamiento simple y desplazamiento implícito, que pueden ser aplicados al método  $QR$ .

- **Desplazamiento Simple:** esta técnica está basada en el hecho de que un desplazamiento causado por un autovalor provoca una deflación, por lo tanto es sugerido seleccionar el desplazamiento  $\sigma_k$  como un autovalor aproximado. Se puede seleccionar el elemento  $(k, k)$  de la matriz  $A^{(k)}$  como valor de desplazamiento.
- **Desplazamiento Implícito:** se busca el autovalor de la matriz  $2 \times 2$  más cercano al elemento de la diagonal, la diferencia radica en llevar a cabo la transformación  $QR$  sin substraer el desplazamiento de los elementos de la diagonal, como es llevado a cabo en los desplazamientos anteriores.

## Criterio de Parada

- El algoritmo  $QR$  presenta un proceso iterativo para hallar los autovalores de una matriz  $A$ , pero en el proceso se debe indicar cual es el criterio a seguir, para indicar que se ha hallado un autovalor.

# Criterio de Parada

- El algoritmo  $QR$  presenta un proceso iterativo para hallar los autovalores de una matriz  $A$ , pero en el proceso se debe indicar cual es el criterio a seguir, para indicar que se ha hallado un autovalor.
- Un criterio que se emplea en muchas de las implementaciones del algoritmo  $QR$ , es el propuesto por Wilkinson, en el que se compara el elemento de la subdiagonal con los elementos vecinos de la diagonal. De esta manera, en la iteración  $k$ , el elemento  $a_{i,i-1}^{(k)}$  es colocado en cero si se cumple que

$$a_{i,i-1}^{(k)} \leq u \left( |a_{i-1,i-1}^{(k)}| + |a_{i,i}^{(k)}| \right)$$

## Criterio de Parada

- El algoritmo  $QR$  presenta un proceso iterativo para hallar los autovalores de una matriz  $A$ , pero en el proceso se debe indicar cual es el criterio a seguir, para indicar que se ha hallado un autovalor.
- Un criterio que se emplea en muchas de las implementaciones del algoritmo  $QR$ , es el propuesto por Wilkinson, en el que se compara el elemento de la subdiagonal con los elementos vecinos de la diagonal. De esta manera, en la iteración  $k$ , el elemento  $a_{i,i-1}^{(k)}$  es colocado en cero si se cumple que

$$a_{i,i-1}^{(k)} \leq u \left( |a_{i-1,i-1}^{(k)}| + |a_{i,i}^{(k)}| \right)$$

- El criterio dado es esencialmente una prueba heurística, ya que a pesar de ser utilizada y cuyo comportamiento ha sido el correcto, no hay una teoría matemática que la sostenga.